# Algorytm znajdowania sumy podzbioru

(Algorithm for subset sum problem)

Łukasz Wasilewski

Praca licencjacka

**Promotor:** dr Paweł Gawrychowski i mgr Karol Pokorski

Uniwersytet Wrocławski Wydział Matematyki i Informatyki Instytut Informatyki

16 lutego 2023

#### Streszczenie

Problem istnienia podzbioru o sumie t zawierającego się w n-elementowym (multi)zbiorze  $S \subset \mathbb{N}$ , jest jednym z klasycznych problemów algorytmicznych. Problem w ogólności jest problemem NP-zupełnym [1] jednak jeżeli t jest względnie małe i dysponujemy pamięcią  $\Omega(t)$  istnieją algorytmy działające w czasie wielomianowym od długości wejścia, z czego najbardziej znanym jest działający w czasie O(nt) algorytm oparty na programowaniu dynamicznym.

Celem niniejszej pracy jest dokumentacja implementacji algorytmu opracowanego przez Ce Jin i Hongxun Wu w pracy [10]. Algorytm ten jest niedeterministyczny, jednak dla dużych danych prawdopodobieństwo błędu jest niewielkie. Złożoność czasowa prezentowanego algorytmu to  $O((t+n)\log^2(t))$ , zaś pamięciowa O(n+t).

#### Abstract

The problem of the existence of a subset with the sum t contained in the n-element (multi)set  $S \subset \mathbb{N}$ , is one of the classic algorithmic problems. The problem in general is a NP-complete [1] however, if t is relatively small and  $\Omega(t)$  memory is available, there are algorithms that work in polynomial time on the length of the input, the most famous of which is running in time O(nt) dynamic programming algorithm.

The purpose of this paper is to document the implementation algorithm developed by Ce Jin and Hongxun Wu in [10]. This algorithm is non-deterministic, however, for large data, the probability of error is low. The time complexity of the presented algorithm is  $O((t+n)\log^2(t))$ , and memory is O(n+t)

# Spis treści

1	Wstęp	3
2	Algorytm klasyczny	3
3	Idea algorytmu Ce Jin i Hongxun Wu	4
4	Implementacja ciała $\mathbb{Z}_p$	5
5	Szukanie liczby pierwszej	9
6	Teorioliczbowa szybka transformata Fouriera	12
7	Pochodna algebraiczna i jej własności	16
8	Implementacja algorytmu Jin i Wu	17
9	Wyniki	19

#### 1 Wstęp

Problem sprawdzenia czy z n-elementowego multizbioru S liczb naturalnych jesteśmy w stanie wybrać podzbiór, którego suma elementów jest równa zadanej liczbie t jest jednym z klasycznych problemów algorytmicznych. Będziemy go w dalszej części nazywać **problem sumy podzbioru**.

Ma on zastosowanie w licznych praktycznych zagadnieniach na przykład kryptografii [1], analizie finansowej [4], czy zagadnieniach kombinatorycznych, jako specyficzny wariant problemu plecakowego (Problem plecakowy dotyczy możliwości wybrania ze zbioru przedmiotów, z których każdy ma określoną wagę i wartość, podzbioru mającego maksymalną sumaryczną wartość i jednocześnie, którego sumaryczna waga nie przekracza pewnej liczby t. Problem sumy podzbiorów odpowiada sytuacji, gdy wartości przedmiotów są wprost proporcjonalne do ich wagi).

Klasyczna wersja problemu, gdzie t jest duże (gdy nie dysponujemy O(t) pamięci) jest problemem NP-zupełnym [12]. Najprostszy algorytm rozwiązujący ten problem polega na rozważeniu po kolei wszystkich możliwych podzbiorów. Złożoność tego algorytmu to  $O(n2^n)$ . Nieco szybszym algorytmem jest algorytm Horowitza i Sahaniego [8] który działa w  $O(2^{\frac{n}{2}}n/2)$ , jednak w przeciwieństwie do algorytmu naiwnego wymagającego O(n) pamięci algorytm ten wymaga  $O(2^{\frac{n}{2}})$ . Algorytm Schroeppela i Shamira [13] wymaga takiego samego czasu jak algorytm Horowitza i Sahaniego, jednak potrzebuje  $O(2^{\frac{n}{4}})$  pamięci. Probabilistyczny algorytm Howgrave-Grahama i Jouxa [9] pozwolił przyspieszyć rozwiązanie problemu do  $O(2^{0.337n})$  zużywając  $O(2^{0.256})$  pamięci. Dalsze jego ulepszenia pozwoliły osiągnąć złożoność czasową równą  $O(2^{0.291n})$  [3].

Znacznie mniej czasu wymagają instancje problemu sumy podzbiorów, gdzie t jest względnie małe i dysponujemy O(t) pamięci. Oparty o programowanie dynamiczne klasyczny algorytm wymaga O(nt) czasu i O(n+t) pamięci. Używam go do sprawdzenia poprawności implementacji algorytmu Ce Jin i Hongxun Wu. Najszybszym znanym algorytmem deterministycznym dla problemu sumy podzbiorów z małym t jest algorytm Konstantinos Koiliaris i Chao Xu [2].

Algorytm, który prezentuję w niniejszej pracy został opracowany przez Ce Jin i Honguxun Wu. Działa on w czasie  $O(n+t\log^2(t))$  i wymaga O(n+t) pamięci. Jest to algorytm probabilistyczny z prawdopodobieństwem błędu  $O(\frac{1}{n+t})$ . Moja implementacja składa się z 4 modułów: klasy field odpowiadającej symulacji działań w ciele  $\mathbb{Z}_p$  reszt z dzielenia przez liczbę pierwszą p, moduł losujący liczbę p korzystający z testu Millera-Rabina, moduł zawierający implementację teorioliczbowej szybkiej transformaty Fouriera (jest to pewna modyfikacja względem pracy Ce Jin i Honguxun Wu, ponieważ proponowali oni szybką transformatę Fouriera, jednak początkowe próby jej implementacji powodowały problemy związane z niedokładnością operacji zmiennoprzecinkowych) oraz implementacja algorytmu właściwego.

Moja implementacja jest napisana w języku C++ i korzysta ze zmiennych całkowitych 128-bitowych więc kompilacja może nie powieść się na niektórych systemach i kompilatorach, w szczególności na systemach 32-bitowych. Dokładne wymagania opiszę w dalszej części pracy.

W niniejszej pracy zaprezentuję niedeterministyczny algorytm opracowany przez Ce Jin i Hongxun Wu, który korzystając ze sprytnych obserwacji na polu analizy matematycznej i algebry jest w stanie podać wynik w czasie  $O(n+t\log^2(t))$ , co jest czasem znacznie szybszym niż klasyczny algorytm oparty na programowanie dynamiczne.

Kody opisanych programów są umieszczone w repozytorium https://github.com/Lukasz112358/licencjat2.

## 2 Algorytm klasyczny

Specyfikacja problemu sumy podzbiorów, który będziemy rozwiązywać jest następująca:

Wejście: Liczba naturalna n, liczba naturalna t, zbiór S reprezentowany jako ciąg n liczba naturalnych.

**Wyjście:** true jeżeli istnieje  $S' \subseteq S$ , którego suma elementów jest równa t lub false w przeciwnym przypadku.

Lub alternatywnie

Wejście: Liczba naturalna n, liczba naturalna t, zbiór S reprezentowany jako ciąg n liczb naturalnych.

**Wyjście:** t+1-elementowy wektor ans wartości boolowskich taki, że dla każdego  $i \in \{0,1,2,...,t\}$  ans[i]==true wtedy i tylko wtedy, gdy istnieje  $S' \subseteq S$ , którego suma elementów jest równa t.

Klasyczny algorytm [11] opiera się na modyfikacji t+1-elementowej tablicy DP o komórkach przyjmujących wartości bool-owskie i opiera się na programowaniu dynamicznym. Początkowo wszystkie komórki DP są ustawione na false, oprócz komórki 0-owej, która jest ustawiona na true.

Dokładny algorytm przedstawia poniższy pseudokod (odpowiada on drugiej specyfikacji problemu sumy podzbiorów. Jeżeli chcielibyśmy odpowiedź na pierwszą jego wersję wystarczy zwrócić DP[t], przy czym można przerwać działanie programu razu gdy DP[t] przyjmie wartość true. wartość true).

```
\begin{array}{l} DP \leftarrow \text{Vector}(\textbf{t}, \text{false}) \\ DPold \leftarrow \text{Vector}(\textbf{t}, \text{false}) \\ DPold[0] = \textbf{true} \\ \textbf{for } i \leftarrow \textbf{0}, \textbf{1}, \dots, \textbf{n-1 do} \\ & | \textbf{for } j \leftarrow \textbf{S[i]}, \textbf{S[i]+1}, \dots, \textbf{t do} \\ & | DP[j] = \text{oldDP[j] or oldDP[j-S[i]]} \\ & \textbf{end} \\ & DPold = DP \\ \textbf{end} \end{array}
```

Dowód poprawności tego algorytmu jest prostym dowodem indukcyjnym, w którym teza indukcyjna brzmi: po wykonaniu *i*-tej iteracji pętli, dla każdego  $m \in \{0, 1, ..., t\}$  DP[m]==true wtedy i tylko wtedy gdy można wybrać podzbiór zbioru  $\{S[0], S[1], ..., S[i]\}$  taki, że suma jego elementów wynosi m.

- Dla i = 0 teza jest oczywista.
- Załóżmy, że teza jest prawdziwa dla 0,1,2,...,i-1. Jeżeli istnieje podzbiór zbioru  $\{S\,[0]\,,S\,[1]\,,...,S\,[i]\}$  taki, że suma jego elementów wynosi k to jest to albo podzbiór zbioru  $\{S\,[0]\,,S\,[1]\,,...,S\,[i-1]\}$  i z tezy indukcyjnej DP[k]==true jeszcze przed wykonaniem i-tej iteracji albo jest to podzbiór zawierający element  $S\,[i]$ , którego pozostałe elementy należące do  $\{S\,[0]\,,S\,[1]\,,...,S\,[i-1]\}$  sumują się do k-S[i], więc z tezy indukcyjnej DP[k-S[i]]==true. Ponieważ DP[k] po wykonaniu i-tej iteracji przyjmuje wartość DP[i] or DP[k-S[i]] teza indukcyjna jest prawdziwa.

Ponieważ komórki DP przyjmują tylko wartości true i false do reprezentacji ich najoptymalniej jest użyć bitsetu, a kolejne iteracje pętli zewnętrznej wykonać poleceniem DP |= (DP » S[i]).

Pętla zewnętrzna wykona się O(n) razy i każda iteracja zajmie O(t) czasu tak więc czas działania całego algorytmu zajmie O(nt) i O(t+n) pamięci.

Algorytm naiwny został zaimplementowany w pliku main.cpp jako funkcja brutalSum.

### 3 Idea algorytmu Ce Jin i Hongxun Wu

Algorytm Ce Jin i Hongxun Wu bazuje na dość prostej obserwacji, że dla danego zbioru  $S = \{s_1, s_2, ..., s_n\} \subset \mathbb{N}$  istnieje jego podzbiór sumujący się do  $t \in \mathbb{N}$  wtedy i tylko wtedy gdy, współczynnik przy  $x^t$  w wielomianie  $A(x) := \prod_{i=1}^n (1+x^{s_i})$  jest niezerowy. Istotnie jeżeli ten współczynnik jest niezerowy, to istnieje ciąg indeksów  $0 < i_1 < i_2 < ... < i_k < n+1$  taki, że

$$\prod_{i=1}^{k} x^{s_{i_j}} = x^{\sum_{j=1}^{k} s_{i_j}} = x^t$$

Tak więc ciąg ten odpowiada indeksom elementów, które należy wybrać by uzyskać podzbiór zbioru S o sumie elementów równej t. Zamiast liczyć ten współczynnik wprost, najpierw obliczymy  $B(x) := \ln(\prod_{i=1}^{n} (1+x^{s_i}))$ , zaś następnie,  $\exp(B(x)) = A(x)$ .

Co to jednak znaczy, że obliczymy te funkcje? Będziemy wyliczać rozwinięcia jej w szereg Taylora. Współczynnik przy  $x^t$  w rozwinięciu w szereg Taylora  $\exp(B(x))$  istotnie, jest współczynnikiem przy

 $x^t$  w A(x). Wynika to bezpośrednio z jednoznaczności rozwinięcia w szereg potęgowy i tego, że A(x)jest wielomianem.

W dalszej części sekcji dla funkcji  $F(x) = \sum_{i=0}^{\infty} a_i x^i$ , jako  $F_t(x)$  będę oznaczał  $\sum_{i=0}^{t} a_i x^i$ . Tak więc  $\exp_t(x) = \sum_{i=0}^{t} \frac{x^i}{i!}$ , zaś  $\ln_t(1+x^a) = \sum_{i=0}^{\lfloor \frac{t}{a} \rfloor} \frac{(-1)^{i+1} x^{ai}}{i}$ . Aby znaleźć odpowiedź na omawiany w tej pracy problem wystarczy oczywiście ustalić jedynie

wartość t pierwszych wyrazów rozwinięcia w szereg Taylora funkcji  $\exp(B(x))$ .

Niestety obliczenia potrzebne do znalezienia tych współczynników mogą wymagać użycia bardzo dużych liczb długości O(n). Obliczenia na nich mogą być więc czasochłonne.

Ce Jin i Hongxun Wu skorzystali z faktu, że pochodna nie jest jedynie obiektem, który można zde- $\lim_{h\to 0} \frac{f(x+h)-f(x)}{h}$ , ale i przekształcenie czysto algebraiczne, które przekształca szereg  $\sum_{i=0}^{\infty} f_i x^i$  w  $\sum_{i=1}^{\infty} i f_i i x^{i-1}$ . finiować analitycznie jako przekształcenie funkcji f(x) w funkcję zwracającą dla argumentu x wartość

Tak zdefiniowana pochodna zachowuje pewne algebraiczne właściwości (f' + g' = (f + g)', (fg)' =f'g + g'f, (f(g))' = f'(g)g') bez względu na to do jakiego ciała należą współczynniki tych szeregów, tak więc również pojęcie szeregu Taylora (z pewnymi ograniczeniami) możemy rozpatrywać w innych ciałach niż  $\mathbb{R}$ . W naszym przypadku będzie to ciało  $\mathbb{Z}_p$  reszt z dzielenia przez p, gdzie p jest losową liczbą pierwszą na tyle dużą, że prawdopodobieństwo fałszywego zakwalifikowania jakiejś liczby jako 0 jest niewielkie, jednak na tyle małą, że obliczenia na elementach  $\mathbb{Z}_p$  wykonują się względnie szybko.

Ważną optymalizacją w liczeniu współczynników rozwinięcia  $\exp(B(x))$  było zastąpienie naiwnych obliczeń zajmujących czas  $O(t^2)$ , pomnożeniem dwóch wielomianów stopnia co najwyżej O(t), co można wykonać szybką transformatą Fouriera w czasie  $O(\log(t)t)$ . Aby uniknąć problemów z utratą dokładności w obliczeniach na liczbach zmiennoprzecinkowych zastosowałem Teorioliczbowa szybką transformatę Fouriera, w której współczynniki rozpatrywałem w ciele wylosowanej już na potrzeby wcześniej omawianych obliczeń liczby p.

Ogólnie implementację algorytmu można podzielić na 5 zasadniczych części

- Implementacja funkcji losującej liczbę pierwszą p o pożądanych własnościach.
- Implementacja klasy odpowiadającej za wykonywanie obliczeń w ciele  $\mathbb{Z}_p$ .
- Implementacja Teorioliczbowej szybkiej transformaty Fouriera w ciele  $\mathbb{Z}_p$ .
- Implementacja algorytmu właściwego.
- Implementacja kodu testującego, w tym algorytmu naiwnego.

#### Implementacja ciała $\mathbb{Z}_{p}$ 4

Ogólny szablon, jakie metody należy zaimplementować był mocno inspirowany implementacja klasy dużych liczb całkowitych zamieszczony na stronie https://www.geeksforgeeks.org/bigint-big-integersin-c-with-example/.

Ponieważ znaczną część obliczeń mój program wykonuje na elementach ciała  $\mathbb{Z}_p$ , w którym istnieją działania arytmetyczne, aby uniknąć konieczności ciągłych operacji pobierania explicite wartości modulo p z wyników działań najwygodniejszym podejściem jest zaprogramowanie klasy field, której instancje reprezentują elementy ciała  $\mathbb{Z}_p$  zaś przeciążone operatory odpowiadają działaniom w  $\mathbb{Z}_p$  i pisząc bardziej wysokopoziomowy kod nie muszę już się troszczyć o to, by jakkolwiek "normalizować" wyniki.

Klasa ma kilka pól statycznych. Jednym z nich jest liczba p typu \_\_int128 będąca liczbą pierwszą modulo, która będziemy wykonywać nasze obliczenia. Liczba m typu \_\_int128, która ma zastosowanie przy wykonywaniu działania mnożenia w sposób chroniący nas przed przepełnieniem zmiennej co zostanie omówione w dalszej części.

Liczbę p można zapisać jako  $2^k r + 1$ , gdzie r jest liczbą nieparzystą zaś k liczbą naturalną. W zmiennej statycznej typu \_\_int128 i nazwie odd przechowujemy wartość owego r, zaś w statycznej zmiennej degree0fDegree typu \_\_int128 przechowujemy wartość owego k.

Dla każdej liczby pierwszej p istnieje pierwiastek pierwotny, czyli taka liczba, że x, że nie istnieje dodatnia liczba naturalna w mniejsza niż p-1 taka, że  $x^w\equiv 1\pmod p$  (oczywiście z małego twierdzenia Fermata  $r^{p-1} \equiv 1 \pmod{p}$ ). W dalszej części pracy stopniem liczby/pierwiastka będę oznaczał najmniejszy wykładnik naturalny do którego należy ją podnieść, aby uzyskać 1 w ciele  $Z_p$ . Stopień pierwiastka pierwotnego wynosi oczywiście p-1. Bardzo często będziemy chcieli szybko wyliczyć liczbę mającą stopień będący potęgą 2 o wykładniku naturalnym k. Najprościej taką liczbę uzyskać jako rezultat potęgowania pierwiastka pierwotnego, najpierw do potęgi, której wykładnik jest równy wartości zmiennej statycznej odd, a następnie, wykonaniu degreeOfDegree-k podniesień wyniku do kwadratu. Wygodnie byłoby nie musieć za każdym razem wykonywać potęgowania do potęgi odd, dlatego w zmiennej statycznej almostPrimitiveRoot typu \_\_int128 przechowuję wartość będącą wynikiem podniesienia pierwiastka pierwotnego do potęgi odd.

Ostatnim polem statycznym klasy field jest struktura typu std::map<\_\_int128 , \_\_int128 > i nazwie inverse przechowująca odwrotności elementów ciała. Będzie ona dynamicznie powiększana w trakcie wykonania programu i służy ominięciu konieczności wykonywania dużej ilości powtórzeń kosztownej operacji liczenia odwrotności elementu.

Metoda setP ustawia wartość p na przyjętą jako argument wartość zmiennej x typu \_\_int128. Ustawia ona również zmienną m na wartość  $\lfloor \frac{2^{127}-1}{p} \rfloor$ . Czyści tablicę inverse (wcześniej wyliczone odwrotności elementów po zmianie ciała przestają być dłużej odwrotnościami tych samych elementów). Wykonując poniższy kod znajduję wartość pól degree0fDegree (w zmiennej degree) oraz odd(w zmiennej y) i następnie, przypisujemy je odpowiednim polom.

```
__int128 y = field::p - 1;
__int128 degree = 0;
while(y % 2 == 0){
    degree++;
    y /= 2;
}
```

Następnie szukamy wartości pola almost PrimitiveRoot. Przy założeniu prawdziwości hipotezy Riemanna pierwiastek pierwotny modulo p jest stosunkowo mały wielkości  $O(\log^6(p))$  [5], tak więc kandydatów możemy szukać sprawdzając kolejne liczby naturalne zaczynając od 2. Tak naprawdę nie potrzebujemy wyznaczyć pierwiastka pierwotnego, ale jedynie liczbę jedynie liczbę r, że nie zachodzi,  $r^{2^{d-1}}\equiv 1\pmod p$ , gdzie d to wartość zmiennej degree OfDegree. Sprawdzenie dla liczby rczy nie zachodzi,  $r^{2^{\frac{p-1}{2}}}\equiv 1\pmod p$  jest mocniejszym warunkiem i dla uproszczenia kodu on zostaje sprawdzony. Następnie jeżeli wspomniany warunek zachodzi, do zmiennej almost PrimitiveRoot zapisujemy  $r^{odd}$ 

W module zajmującym losowaniem liczb pierwszych istnieje miejsce, w którym wykonujemy operacje modularne modulo liczb, które nie muszą być pierwsze jednak nie wykonujemy dzielenia. Wygodnie byłoby móc użyć metod klasy field. Aby uniknąć potencjalnych niespodziewanych zachowań programu na przykład podczas wyznaczania wartości pola almostPrimitiveRoot podczas wywołania funkcji setP na argumencie niebędącym liczbą pierwszą utworzyłem funkcję setPsilly, która przyjmuje argument x typu \_\_int128 i ustawia na niego wartość pola p, wartość pola m ustawia podobnie jak w funkcji setP na  $\lfloor \frac{2^{127}-1}{p} \rfloor$ , pozostałe pola statyczne zaś ustawia na 0 i czyści tablicę odwrotności. Metoda setP służy rozszerzeniu funkcjonalności klasy field o możliwość symulacji obliczeń w pierścieniu  $\mathbb{Z}_n$ , gdzie n nie jest liczbą pierwszą.

Pole, które przechowuje wartość pojedynczego obiektu nazwałem value. Oczywiście pole to już nie może być statyczne. Stworzyłem kilka konstruktorów dla klasy field. Konstruktor domyślny nie przyjmuje żadnego argumentu i ustawia wartość value na 0. Konstruktor kopiujący ustawia wartość value na wartość value obiektu typu field podanego jako argument.

Ostatni konstruktor przyjmuje liczbę całkowitą val typu \_\_int128. Żeby uniknąć nietypowych zachowań programu chcemy, żeby wartości value dla każdego obiektu klasy field były mniejsze niż p i większe niż 0. Jeżeli więc wartość val jest większa lub równa 0 polu value przypisuję jej resztę z dzielenia przez p. Jeżeli jest zaś jest ujemna przypisuję mu wynik działania ((val%p)+p)%p.

Przejdę teraz do omówienia kolejnych funkcji i przeciążonych operatorów w omawianej klasie.

Utworzyłem kilka get-terów, żeby w sposób bardziej kontrolowany odwoływać się do niepublicznych pól. getP, getM, getAlmostPrimitiveRoot, getOdd, getDegreeOfDegree służą odpowiednio do pobrania wartości pól p, m i almostPrimitiveRoot.

Metody friend field inline & operator++(), friend field inline operator++(int temp), friend field inline & operator-(), friend field inline & operator++(int temp) to odpowiednio przeciążenia operatora postinkrementacji, preinkrementacji, postdekrementacji i predekrementacji. Operator postinkrementacji korzystając z niezmiennika, mówiącego, że wartość pola value jest zawsze

liczbą całkowitą z przedziału [0,1,...,p-1], który zachowują wszystkie funkcje oraz konstruktory modyfikujące pole value może przypisać polu value po prostu wartość wyrażenia (value+1)%field::p. Jeżeli value==0 naiwna postdekrementacja powoduje uzyskanie wyniku ujemnego dlatego polu value w przypadku postdekrementacji zamiast (value+1)%field::p przypisujemy (field::p+value-1)%field::p. Dla operatora preinkrementacji, najpierw tworzymy zmienną aux, w której przechowujemy starą wartość obiektu, którą później zwrócimy, a następnie, na oryginalnym obiekcie dokonujemy zdefiniowaną wcześniej postinkrementację. Operator predekrementacji definiujemy analogicznie jak preinkrementacji.

Następnie definiuję przeciążenia operatorów friend inline field &operator+=, friend inline field &operator-=, friend inline field &operator-. Operator += przyjmuje przez referencję dwa argumenty typu field, gdzie pierwszy oznaczam jako a, zaś drugi jako b. Wartości pola value przypisujemy wartość ( a.value + b.value ) %field::p, gdzie operator % służy zachowaniu niezmiennika, by wartości pola value były mniejsze niż p. Z kolei dla operatora -= wartości analogicznego, pola przypisujemy wartość wyrażenia (a.value-b.value+field::p)%field::p gdzie nieobecne w poprzednim przypadku dodanie p służy niedopuszczeniu do sytuacji gdy value stanie się ujemne jeśli b.value>a.value. W implementacji operatora + tworzymy tymczasowy obiekt temp klasy field o wartości początkowej pola value równej a.value, a następnie, przy pomocy zdefiniowanego wcześniej operatora += dodajemy do tego obiektu obiekt b. Analogicznie definiujemy operator

Kolejnymi nieco prostszymi operatorami jakie zdefiniowałem to operatory porównujące friend inline bool operator==, friend inline bool operator!=, friend inline bool operator<, friend inline bool operator>=, które dla argumentów a i b zwracają wartości boolowskie odpowiednio wyrażeń a.value == b.value, a.value != b.value, a.value <= b.value, a.value >= b.value.

Nieco bardziej skomplikowana jest implementacja operatora friend field &operator\*=. Ponieważ liczba p mnożę być rzędu  $O(t(n+t)^3)$  gdybyśmy postąpili naiwnie i (przyjmując oznaczenie pierwszego argumentu jako a, drugiego jako b) przypisali polu value wyniku wartość wyrażenia (a.value\*b.value)%field::p oznaczałoby to pobranie reszty z dzielenia przez p z wartości wyrażenia a.value\*b.value, która byłaby rzędu  $O(t^2(n+t)^6)$ , co już dla t rzędu  $10^5$  mogłoby powodować wychodzenie poza zakres nawet zmiennej typu \_\_int128. Oczywiście tak mały zakres liczb mocno wpłynąłby na użyteczność zaimplementowanych funkcji. Definiuję więc zmienną m, będącą górną wartością b, dla którego możemy wykonać mnożenie w sposób naiwny (i następnie, wyciągnąć tylko resztę z dzielenia przez p) bez obaw o przepełnienie. W przeciwnym wypadku tworzę zmienną pomocniczą A będącą wartością pola value obiektu a oraz zmienna B bedącą wartością pola value obiektu b.

Na potrzeby dalszej części pracy definiuję operator matematyczny %, który dla lewego argumentu będącego liczbą naturalną A i prawego będącego liczbą naturalną dodatnią B zwraca resztę z dzielenia A przez B. Jest więc bardzo podobny do operatora % w składni C++.

Zauważmy, że  $A \cdot B = A \cdot \lfloor \frac{B}{m} \rfloor + A \cdot (B\%m)$ . Wartość m jest zależna od p i dlatego ustawiamy ją podczas operacji setP o czym pisałem w jednym poprzednich akapitów. Inicjalizuję obiekt ans1 klasy field o wartości pola value równej A. Następnie mnożę go rekurencyjnie przy pomocy operatora \*= przez field(field::m), a następnie, przez field(B/field::m). Inicjalizuję też obiekt ans2 o początkowej wartości pola value równej A i mnożę rekurencyjnie przy pomocy operatora \*= przez field(B%field::m). Po tych operacjach wartość pola value obiektu ans1 wynosi  $A \cdot \lfloor \frac{B}{m} \rfloor$ , zaś obiektu ans2  $A \cdot (B\%m)$ . Do a zapisujemy więc ans1+ans2 i zwracamy a.

Kolejnym operatorem jest operator friend field operator\*. Argumenty, które otrzymuje to obiekty typu field o nazwach a i b. Tworzę tymczasowy obiekt typu field i nazwie temp o tej samej wartości pola value co a i następnie, mnożę go przez b przy pomocy zdefiniowanego wcześniej operatora \*= i zwracam tak zmodyfikowany obiekt temp.

Kolejnym operatorem jest operator potęgowania friend field inline &operator^=. Pierwszym argumentem jaki przyjmuje jest obiekt typu field o nazwie a oraz zmienna typu \_\_int128 o nazwie b. Zauważmy, że z małego twierdzenia Fermata (jeżeli p nie dzieli a, jeżeli jednak dzieli również własność zachodzi, czego dowód jest trywialny)  $a^{k(p-1)+l} \equiv (a^{p-1})^k a^l \equiv 1^k a^l \equiv a^l \pmod{p}$  dla dowolnych naturalnych a, k, l, tak więc zamiast podnosić a do potęgi b możemy podnieść ją do potęgi b%(p-1). Teoretycznie moglibyśmy rozpatrywać ((b%(p-1))+p-1) % (p - 1), jednak z pewnych powodów, o

których napiszę w dalszej części pracy zdecydowałem się rozpatrzyć przypadki b ujemnego i dodatniego osobno.

Należy również pamiętać, że po zaimplementowaniu funkcji setPsilly nasza klasa może symulować niektóre działania modulo p dla p nie będącego liczbą pierwszą. Oczywiście wtedy małe twierdzenie Fermata przestaje pozwalać na ową redukcję b do reszty z dzielenia przez p-1, tak więc przypadek ten skorygowałem prostym if-em, sprawdzającym czy wartość pola odd jest równa 0, co może się zdarzyć tylko wtedy gdy klasa jest inicjalizowana funkcją setPsilly.

Jeżeli b==0, przypisuję a wartość 1 i zwracam wynik. Jeżeli b==1 nie robię nic, tylko od razu zwracam a. Jeżeli b==-1 to jeżeli a.value==0 wyrzucam błąd dzielenia przez 0, jeżeli zaś nie wykonuję następującą procedurę. Ponieważ potęgowanie do -1 to znalezienie odwrotności a w  $\mathbb{Z}_p$  z małego twierdzenia Fermata oznacza to podniesienie a do potęgi p-2. Potęgowanie można zaimplementować, by wykonywało się w czasie logarytmicznym względem stopnia, jednak mnożenie ze względu na groźbę przepełnienia też może w pesymistycznym przypadku zabierać logarytmicznie dużo czasu. Znalezienie odwrotności obiektu jest dość podstawową operacją, którą możemy chcieć wykonywać bardzo często, tak więc czas  $O(\log^2(p))$  może nie być zadowalający. Dlatego klasa field posiada jeszcze jedno pole, którym jest statyczna mapa o nazwie inverse z wejściami typu <\_\_int128,\_\_int128>, która przypisuje liczbie x liczbę, która jest wartością odwrotną w ciele  $\mathbb{Z}_p$ . Mapę tą czyścimy, za każdym razem gdy zmieniamy wartość p. Istotnie wtedy odwrotności tych samych liczb mogą stać się inne, bo zmienia się ciało, w którym są tymi odwrotnościami. Operacja insertInverse przyjmuje zmienne typu field, które zakładamy explicite, że są elementami wzajemnie odwrotnymi i oznaczamy je jako a oraz b, a następnie, jako, że  $(a^{-1})^{-1} = a$  wykonujemy od razu 2 przypisania

```
field::inverse[a.value] = b.value;
field::inverse[b.value] = a.value;
```

Gdy mamy wyliczyć potęgę o wykładniku -1 jakiegoś elementu a typu field sprawdzam, najpierw czy w mapie odwrotności jest przypisana wartość dla klucza a.value, a następnie, jeżeli kluczowi temu przypisana jest wartość ustawiamy a.value na nią i zwracamy a, zaś w przeciwnym przypadku wykonujemy operację field::insertInverse(a,  $A^=((long long)(field::p-2)))$ , gdzie A to kopia obiektu a. (rekurencyjnie wywołujemy operator = dla wartości nieujemnej) i ponownie pobieramy wartość dla klucza a.value. Pozwala nam to dla każdego elementu  $\mathbb{Z}_p$  wyliczyć jego odwrotność co najwyżej raz, bez względu na ilość wywołań tego wyliczenia w wyżej poziomowym kodzie.

Kolejnym przypadkiem, który należy rozważyć to gdy b>1. Wykonuję wtedy iteracyjną wersję szybkiego potęgowania. Tworzę pomocniczy obiekt multiplier będący kopią a oraz obiekt ans o wartości pola value równej 1. Następnie wykonuję pętlę

```
while(b != 0){
    if(b % 2 == 1)ans *= multiplier;
    multiplier *= multiplier;
    b /=2;
}
```

i następnie, kopiuję wartość ans do obiektu a oraz zwracam a.

Kolejnym i już ostatnim przypadkiem jest gdy b < -1. W tym przypadku wykorzystujemy fakt, że  $a^b = (a^{-1})^{-b}$ . Tak więc kolejno wykonujemy zdefiniowane wcześniej podniesienie a do potęgi -1 przy pomocy operatora  $^{\wedge}$  = a następnie, znów przy pomocy tego samego operatora podnosimy a do potęgi -b>1, co też zostało już wcześniej zdefiniowane. Po wykonaniu tych obliczeń zwracam a.

Kolejnym operatorem jest ^. Pobiera on argument a typu field i b typu \_\_int128, tworzy przy pomocy konstruktora kopiującego tymczasowy obiekt temp typu field z taką samą wartością pola value co a, następnie, przy pomocy operatora ^= podnosi temp do potęgi B i zwraca tak zmodyfikowaną wartość temp.

Kolejnym operatorem będzie operator dzielenia /= przyjmujący dwa argumenty typu field oznaczone odpowiednio jako a i b. Dzielenie w ciele modulo nie oznacza "klasycznego" dzielenia arytmetycznego, ale pomnożenie przez element odwrotny. Tak więc tworzymy nowy obiekt B będący kopią b i mnożymy a przy pomocy operatora \*= przez B^(longlong)(-1). Następnie zwracamy tak zmodyfikowane a.

Kolejnym operatorem jest /. Otrzymuje on dwa argumenty typu field o nazwach a i b. Tworzę obiekt temp typu field i przypisuję mu wartość a, następnie, dzielę przez b przy pomocy operatora \= i zwracam temp.

Kolejnymi operatorami sa operatory strumieniowe

```
std::istream &operator» (std::istream &in,field&a) i
std::ostream &operator«(std::ostream &out,const field &a).
```

Wypisanie/wczytanie elementu będzie polegać na wypisaniu/wczytaniu wartości jego pola value. Jednak kompilator g++ nie ma zdefiniowanych operatorów strumieniowych dla zmiennych typu \_\_int128. Dlatego będę w przypadku operatora », najpierw wczytywał zapis żądanej wartości pola value do zmiennej typu std::string, a następnie, przy pomocy funkcji fromString przekształcał ją do zmiennej typu \_\_int128 i zwracał podany jako argument strumień in. Z kolei w przypadku operatora « będę konwertował zmienną typu \_\_int128 do zmiennej typu std::string i dopiero po konwersji wypisywał na podany jako argument strumień out i zwracał ten strumień.

Funkcja fromString używa funkcji charToDigit, która przyjmując znak x typu char będący zapisem jakiejś cyfry w języku "ludzkim" zwraca liczbę typu \_\_int128 mającą wartość tej cyfry. Funkcja fromString przyjmuje zmienną x typu std::string jako argument, a następnie, przechodząc w pętli od tyłu po znakach tego słowa dodaje do zmiennej wynikowej ans kolejne potęgi 10 o wykładniku naturalnym pomnożone przez wartość wyniku funkcji charToDigit na rozpatrywanym znaku. Jeżeli zaś napotka na znak - mnoży ans przez -1.

Funkcja toString korzysta z funkcji toStringOneNumber, która przyjmuje liczbę typu \_\_int128 i zwraca zapis jej reszty z dzielenia przez 10 w formie zmiennej typu string. Funkcja toString przyjmuje wartość x typu \_\_int128 Jeżeli x==0 zwraca "0". Jeżeli x jest ujemne zapamiętuje to w zmiennej minus typu bool i następnie, mnoży w miejscu x przez -1. Funkcja inicjalizuję zmienną wynikową ans na słowo puste, a następnie, wykonuje pętlę

```
 \begin{array}{ll} \mathbf{while}(\mathbf{x} \; != \; 0) \{ \\ & \mathbf{ans} \; = \; \mathbf{toStringOneNumber}(\mathbf{x}) + \mathbf{ans} \, ; \\ & \mathbf{x}/{=}10; \\ \} \end{array}
```

W przypadku gdy zmienna minus została ustawiona na true dodaję z przodu wyniku słowo "-". Po wykonaniu omówionych operacji zwracam wynik.

Omówiony w powyższej sekcji kod został napisany w języku C++ i znajduje się w pliku field.h w dołączonym do pracy repozytorium.

### 5 Szukanie liczby pierwszej

W pracy Jin i Wu liczba pierwsza, którą losujemy ma tylko jedno zastosowanie. Jest nim wyznaczenie ciała, w którym będziemy wykonywać nasze obliczenia. Losowanie jej odbywa się spośród liczb na przedziałe  $[t+1,(n+t)^3]$ .

**Definicja:**  $\pi(x)$  jest funkcją  $\mathbb{N} \to \mathbb{N}$  przypisująca argumentowi x liczbę liczb pierwszych nie większych niż x.

Twierdzeniem o liczbach pierwszych [7] mówi, że:

$$\lim_{x \to \infty} \frac{\pi(x)}{\frac{x}{\ln(x)}} = 1$$

Tak więc liczb pierwszych na przedziale  $[t+1,(n+t)^3]$  jest  $\Omega((n+t)^2)$ . Celem naszego algorytmu jest sprawdzenie, czy dla danego multizbioru  $\{x_1,x_2,...,x_n\}\subset \mathbb{N}$  i liczby t współczynnik przy  $x^t$  w wielomianie  $\prod_{i=1}^t (1+x^{s_i})$  jest dodatni. Ponieważ obliczenia wykonujemy w ciele  $\mathbb{Z}_p$ , jeżeli ów współczynnik byłby podzielny przez p, fałszywie uznalibyśmy go za zerowy. Jednak współczynnik ten będzie nie większy od  $2^n$ , tak więc ma najwyżej  $\Omega(n)$  dzielników pierwszych, więc prawdopodobieństwo, że wylosowana liczba dzieli ten współczynnik jest  $O(\frac{1}{n+t})$ 

Różnica między moją implementacją, a algorytmem opisanym przez Ce Jin i Hongxun Wu jest jednak taka, że nie używałem klasycznej wersji szybkiej transformaty Fouriera, opartej na liczbach zespolonych, a teorioliczbowej szybkiej transformaty Fouriera wykonującej obliczenia w ciele  $\mathbb{Z}_p$ . W tym ciele musi istnieć pierwiastek z 1 stopnia r, gdzie r jest postaci  $2^k$  dla pewnej liczby naturalnej k, oraz r jest większe niż stopnień wielomianu, który powstanie po pomnożeniu wielomianów, do których mnożenia używamy naszą transformatę. Mnożone wielomiany są stopnia co najwyżej t, tak

więc przyjmuję, że  $2^k$  to najmniejsza potęga 2 o całkowitym wykładniku większa niż 2t zaś p ma postać  $r2^k+1$ .

**Twierdzenie:**Jeżeli w ciele  $\mathbb{Z}_p$  istnieje pierwiastek stopnia  $2^k$  z 1 to p ma postać  $r2^k+1$ , gdzie r jest liczbą naturalną.

Istotnie dla każdej liczby pierwszej p istnieje jej pierwiastek pierwotny a, którego stopień jest równy p-1, czyli w tym przypadku  $r2^k$ , zaś stopień  $a^r$  jest równy  $2^k$ .

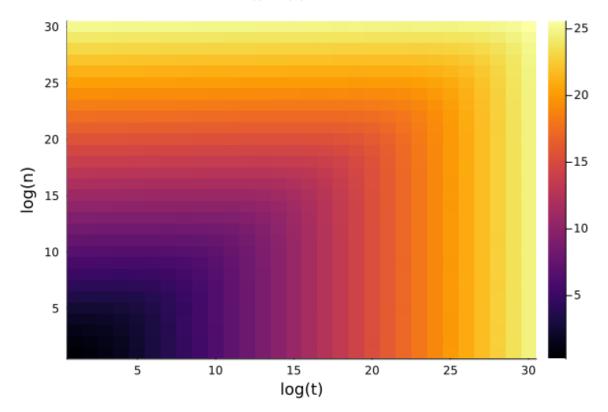
Intuicyjnie można przypuszczać, że ponieważ rozmieszczenie liczb pierwszych jest trudne, do opisania prostym wzorem, to podobny procent liczb postaci  $r2^k+1$ , gdzie r jest liczbą naturalną z przedziału  $[t+1,(n+t)^3]$  jest pierwszy, co po prostu, procent liczb pierwszych na przedziałe  $[t+1,(n+t)^3]$ .

**Definicja**:  $\pi'(x,t)$  to funkcja  $(\mathbb{N}\times\mathbb{N})\to\mathbb{N}$ , która dla argumentów x i t zwraca liczbę liczb pierwszych postaci  $r2^k+1$ , gdzie  $2^k$  to najmniejsza potęga 2 o wykładniku naturalnym większa niż 2t, zaś r jest liczbą naturalną mniejszą lub równą x.

Losowanie liczby pierwszej p o żądanych właściwościach będzie polegać, najpierw na wylosowaniu liczby naturalnej r z przedziału  $[t+1,(n+t)^3]$ , a następnie, wyliczeniu liczby  $k2^r+1$ , gdzie  $2^k$  to najmniejsza potęga 2 o wykładniku naturalnym większa niż 2t i sprawdzeniu, czy tak wyliczona liczba jest pierwsza.

Dla danych t, n, tym sposobem możemy wylosować  $\pi'((n+t)^3, x) - \pi'(t+1, x)$  różnych liczb pierwszych. Jeżeli więc  $\pi'((n+t)^3, x) - \pi'(t+1, x)$  jest co najmniej  $\Omega((n+t)^2)$  to zachodzi, szacowanie prawdopodobieństwa błędu analogiczne do szacowania Jin i Wu. Wyliczenie dokładnej wartości  $\pi'((n+t)^3, x) - \pi'(t+1, x)$  dla dużych n i t jest trudne, dlatego oszacowałem je poprzez losowanie  $10^6$  liczb z przedziału  $[1+t,(n+t)^3]$ , pomnożeniu przez  $2^k$  (gdzie  $2^k$  to najmniejsza potęga 2 o wykładniku naturalnym większa niż 2t) i dodaniu 1, oraz zliczeniu w zmiennej ans ile tak wylosowanych liczb jest pierwszych.  $\frac{a}{1000000}((n+t)^3-(1+t)+1)\approx \pi'(n,t)$ , gdzie a to wartość zmiennej ans na końcu wykonania mojej symulacji.

Poniższa heat-mapa ukazuje tak przybliżoną w ten sposób wartość  $\log_2(\frac{\pi'(n,t)}{(n+t)^2})$ , w zależności od  $\log_2(n)$  i  $\log_2(t)$ . Wyniki eksperymentu pozwalają wnioskować, że liczba liczb pierwszych możliwych do uzyskania w omówiony sposób jest  $\Omega((n+t)^2)$ .



W przeciwieństwie do większości pozostałego kodu, który przygotowałem, ze względu na jednoczesne łatwe wykonywanie wykresów, oraz szybkość działania, eksperymentalne weryfikowanie, omawianej hipotezy przeprowadziłem w języku Julia. Kod użyty do testowania znajduje się w pliku PrimesExperiment.jl.

Omówię teraz już samą implementację modułu szukającego liczby pierwszej. Wszystkie wymienione niżej funkcje zostały zaimplementowane w języku C++ i znajdują się w pliku FindPrimes.cpp.

Moduł losujący składa się z kilku funkcji, z których zdecydowanie najprostszą jest pow2, która dla przyjmowanej jako argument liczby t zwraca najmniejszą potęgę 2 z wykładnikiem naturalnym, która jest większa niż 2t. Polega ona na mnożeniu przez 2 zmiennej ans, której początkowa wartość jest równa 1 dopóki nie będzie większa niż 2\*t. Musimy wykonać co najwyżej 126 mnożeń, co jest na tyle szybkie, że nie ma potrzeby stosowania bardziej zaawansowanych algorytmów jak na przykład używających algorytmu szybkiego potęgowania.

Funkcja random<br/>128 służy do losowania dodatniej liczby typu \_\_int<br/>128 z przedziału [0,1,...,m], gdzie m to wartość zmiennej mod typu \_\_int<br/>128 podanej jako argument. Polega na losowaniu kolejnych bajtów zmiennej ans typu \_\_int<br/>128, a następnie, zwróceniu wartości bezwzględnej jej reszty z dzielenia przez mod.

Sprawdzenie czy wylosowana liczba jest pierwsza wykonuję przy pomocy testu Millera-Rabina.

Jego idea jest następująca: każdą liczbę pierwszą p większą niż 2 da się jednoznacznie zapisać w postaci  $d2^s+1$  gdzie d jest nieparzyste, zaś s naturalne. Dla dowolnej liczby  $a\in\{2,3,...,p-1\}$  z małego twierdzenia Fermata p dzieli

$$a^{p-1} - 1 = a^{d2^s} - 1 = (a^d)^{2^s} - 1 = ((a^d)^{2^{s-1}} + 1)((a^d)^{2^{s-1}} - 1) =$$

$$((a^d)^{2^0} - 1)((a^d)^{2^0} + 1)((a^d)^{2^1} + 1)((a^d)^{2^2} + 1)...((a^d)^{2^{s-1}} + 1)$$

Tak więc z wyboru a wiemy, że któraś z liczb  $(a^d)^{2^0} + 1$ ,  $(a^d)^{2^1} + 1$ ,...,  $(a^d)^{2^{s-1}} + 1$  jest podzielna przez p, czyli dla pewnego  $i \in \{0, 1, 2, ..., s-1\}$  zachodzi,

$$(a^d)^{2^i} + 1 \equiv 0 \pmod{p}$$

czyli równoważnie

$$(a^d)^{2^i} \equiv n - 1 \pmod{p}$$

Test Millera-Rabina opiera się na następującej obserwacji:

**Obserwacja 1:** Dla większej niż 2 liczby  $n=2^sd+1$ , gdzie s jest naturalne, zaś d naturalne nieparzyste i liczby  $a\in\{2,3,...,n-1\}$ , jeżeli istnieje liczba  $i\in\{0,1,2,...,s-1\}$  taka, że  $(a^d)^{2^i}\equiv n-1\pmod p$ , to n prawdopodobnie jest pierwsza. Jeżeli takie i nie istnieje n liczbą pierwszą na pewno nie jest.

Prawdopodobieństwo błedu można minimalizować wybierajac kilka liczb a.

**Fakt 1:** Jeżeli hipoteza Riemanna jest prawdziwa wystarczające jest sprawdzenie a z mniejszych lub równych  $\min(n-2, 2\ln^2(n))$  [5].

Moja implementacja testu Millera Rabina składa z dwóch funkcji.

Pierwsza z nich to MillerRabinOne mająca za zadanie sprawdzić warunek z **Obserwacji 1** dla określonych n i a zwracając false gdy wiemy, że liczba nie jest pierwsza. Na początku rozważam przypadki gdy n i a nie spełniają początkowych założeń dla, których **Hipoteza 1** była formułowana przy pomocy następujących zapytań warunkowych:

```
\begin{array}{l} \textbf{if} (n == 2) \ \textbf{return true}; \\ \textbf{if} (n < 2) \ \textbf{return false}; \\ \textbf{if} (n \% 2 == 0) \ \textbf{return false}; \\ \textbf{if} (a \% n == 1) \ \textbf{return true}; \\ \textbf{if} (a > n) \ \textbf{return true}; \end{array}
```

Jeżeli warunki początkowe są spełnione, przy pomocy funkcji field::setPsilly ustawiam wartości pól statycznych klasy field tak, żeby symulowała ona obliczenia w pierścieniu  $\mathbb{Z}_n$ . Oczywiście nie wszystkie działania zdefiniowane w klasie field działają w pierścieniu  $\mathbb{Z}_n$  (na przykład dzielenie). Jednak możemy to zignorować po prostu ograniczając się do działań dodawania, odejmowania, mnożenia i potęgowania z wykładnikiem naturalnym.

Wyznaczam d i s zgodnie z oznaczeniami z **Hipotezy** 1.

Następnie tworzę obiekt x klasy field z wartością pola value równą a. Podnoszę x do potęgi d przy pomocy operatora ^= zdefiniowanego w module definiującym klasę field. Następnie s-krotnie podnoszę w miejscu x do kwadratu przed każdym kolejnym podniesieniem sprawdzając, czy x==n-1 co oznaczałoby, że liczba n jest "raczej pierwsza" i zwracamy wtedy true lub x==1 co oznaczałoby, że x po kolejnych podniesieniach do kwadratu będzie wciąż równe 1, więc n nie jest pierwsza i zwracamy false. Jeżeli żaden z tych warunków nigdy nie zaszedł po s podniesieniach do kwadratu zwracamy false.

Kolejną funkcją jest MillerRabin, która przyjmuje liczbę n typu \_\_int128 i wywołuje funkcję MillerRabinOne z n jako pierwszym argumentem oraz drugim będącym kolejnymi liczbami ze zbioru  $\{2,3,...,\min(n-2,2\ln^2(n))\}$  i jeżeli, któreś z tych wywołań zwróci false funkcja MillerRabin również zwraca false. Jeżeli jednak tak nie będzie to na podstawie **Faktu 1** zwracamy true oznaczające, że n z bardzo małym prawdopodobieństwem błędu jest pierwsza.

Kolejną już ostatnią funkcją w tym module jest funkcja find\_prime. Przyjmuje ona jako argumenty liczbę n i t, zaś następnie, zwraca liczbę pierwszą postaci  $r2^k+1$ , gdzie r jest liczbą naturalną z przedziału  $[t+1,(n+t)^3]$ . Najpierw przy pomocy wywołania srand((unsigned int)time(NULL)) wprowadzam losowość testu. Następnie przy pomocy funkcji pow2 wyznaczam  $2^k$ . Następnie losuję potencjalne liczby candidate przy pomocy wywołania funkcji random128 na  $(n+t)^3$ . Jeżeli wylosuję liczbę nie większą niż t losuję jeszcze raz. Dla dużych n i t prawdopodobieństwo tego jest znikome, a ewentualny koszt niewielki. Następnie mnożę wylosowane r z wyznaczonym  $2^k$  i dodaję do wyniku 1. Wynik tych operacji zapisuję w zmiennej mod. Kolejnym krokiem jest dla tak uzyskanej liczby sprawdzenie, czy jest pierwsza przy pomocy funkcji MillerRabin. Jeżeli m i t są małe może nie istnieć liczba pierwsza szukanej przez nas postaci, dlatego po wykonaniu 1000000 losowań zwiększam mod dwukrotnie.

Omówione w tej sekcji funkcje znajdują się w pliku  $find\_prime.cpp$  i są napisane w języku C++.

### 6 Teorioliczbowa szybka transformata Fouriera

Dyskretna transformata Fouriera [14] służy przyspieszeniu mnożenia wielomianów. Wielomiany możemy reprezentować jako ciąg współczynników lub jako ciąg wartości w ustalonych punktach, których liczba przekracza stopień reprezentowanego wielomianu. Pierwsza reprezentacja jest wygodna do wyliczania wartości w dowolnym punkcie z dziedziny, jednak mnożenie wielomianów w takiej postaci jest czasochłonne i ma czas kwadratowy od długości wielomianów. Druga reprezentacja pozwala na mnożenie wielomianów w czasie liniowym, jednak wyliczanie ich wartości w innych punktach jest trudne. Dyskretna transformata Fouriera służy do przechodzenia między tymi postaciami w relatywnie szybkim czasie  $O(\log(n)n)$ , gdzie n to stopień tych wielomianów.

Wybór punktów opiera się na prostej obserwacji, że jeżeli  $A(x) = a_0 x^0 + a_1 x^1 + ... + a_{2n-1} x^{2n-1}$  (jeżeli stopień A ma stopień parzysty przyjmujemy po prostu, że  $a_{2n-1}$  jest równe 0) jest równe sumie  $A_0(x^2)$ , gdzie  $A_0(t) = \sum_{i=0}^{n-1} a_{2i} t^i$ , oraz  $A_1(x^2)x$ , gdzie  $A_1(t) = \sum_{i=0}^{n-1} a_{2n+1} t^i$ . Tak więc jeżeli dwie liczby a i b mają te same wartości swoich kwadratów możemy obliczyć tylko raz wartości  $A_1(a^2) = A_1(a^2)$  i  $A_0(a^2) = A_0(b^2)$ , a następnie, w czasie stałym połączyć te wyniki, tak aby uzyskać wartości wielomianu A w punktach a i b.

Klasyczna wersja dyskretnej transformaty Fouriera oblicza wartości wielomianu A dla argumentów z ciała liczb zespolonych. Przyjmujemy następujące oznaczenie  $A(x) = \sum_{i=0}^{\infty} a_i x^i$ , przy czym istnieje I takie, że  $\forall i > I: a_i = 0$ . I oznaczając dalej  $A_0(x) = a_0 x^0 + a_2 x^1 + ... + a_{2^m-2} x^{2^{m-1}-1}$  oraz  $A_1(x) = a_1 x^1 + a_3 x^1 + ... + a_{2^m-1} x^{2^{m-1}-1}$ , przy czym  $2^m$  jest najmniejszą potęgą 2 o wykładniku naturalnym, większym niż stopień wielomianu będącego wynikiem optymalizowanego przez nas mnożenia.

Będę oznaczał  $\omega_m$  jako  $e^{\frac{i2\pi}{2^m}}$ . Zaważmy, że :

$$\begin{cases} A(\omega_m^1) & = A_0(\omega_m^2) + A_1(\omega_m^2)\omega_m^1 = A_0(\omega_{m-1}^1) + A_1(\omega_{m-1}^1)\omega_m^1 \\ A(\omega_m^2) & = A_0(\omega_m^4) + A_1(\omega_m^4)\omega_m^2 = A_0(\omega_{m-1}^2) + A_1(\omega_{m-1}^2)\omega_m^2 \\ A(\omega_m^3) & = A_0(\omega_m^6) + A_1(\omega_m^6)\omega_m^3 = A_0(\omega_{m-1}^3) + A_1(\omega_{m-1}^3)\omega_m^3 \\ & \cdots \\ A(\omega_m^{2^m}) & = A_0(\omega_m^{2^{m+1}}) + A_1(\omega_m^{2^{m+1}})\omega_m^{2^m} = A_0(\omega_{m-1}^2) + A_1(\omega_{m-1}^{2^m})\omega_m^{2^m} \end{cases}$$

Tak więc gdy mamy wektory  $V_0 = \left(A_0(\omega_{m-1}^0), A_0(\omega_{m-1}^1), ..., A_0(\omega_{m-1}^{2^{m-1}-1})\right)$  oraz  $V_1 = \left(A_1(\omega_{m-1}^0), A_1(\omega_{m-1}^1), ..., A_1(\omega_{m-1}^{2^{m-1}-1})\right)$  możemy w czasie liniowym od ich długości wyliczyć wektor  $V = (A(\omega_m^0), A(\omega_m^1), ..., A(\omega_m^{2^m-1}))$ , jednak wyliczenie wektorów  $V_1$  i  $V_2$  można znów rozbić na wyliczenie, najpierw 2 wektorów długości  $2^{m-2}$  i następnie, połączenie tych dwóch wektorów w czasie liniowym od ich długości. Możemy tak rozbijać kolejne wektory aż dojdziemy do wektorów długości 1, które przechowują wartości pewnych wielomianów 0-stopnia będących po prostu jednym ze współczynników A.

Niech T(n) będzie czasem policzenia wartości wielomianu  $A \le n = 2^m$  punktach przy pomocy dyskretnej transformaty Fouriera. Fouriera. Wiemy, że  $T(n) = 2T(\frac{n}{2}) + O(n)$ . Rozwiązaniem takiego równania jest  $T(n) = O(n \log(n))$ . Okazuje się, że po wyliczeniu wartości wielomianu AB w omawianych punktach możemy "wyciągnąć" z tych wartości w czasie  $O(n \log(n))$  wartości współczynników wielomianu AB, gdzie n to ilość tych punktów, tak wiec cały algorytm mnożenia odbywa się w czasie  $O(\log(n)n)$ .

Moja implementacja korzysta z dwóch klasycznych ulepszeń dyskretnej transformaty Fouriera.

Pierwsza to tak zwana "Teorioliczbowa transformata Fouriera" [6]. Polega ona na nie wykonywaniu obliczeń w ciele  $\mathbb{C}$  lecz w  $\mathbb{Z}_p$ , przy czym oczywiście musi w ciele tym istnieć pierwiastek z 1 stopnia  $2^m$ , gdzie  $2^m$  jest potęgą 2 o wykładniku naturalnym i większym niż stopień zwracanego wielomianu. Tak naprawdę oznacza to po prostu, że p ma postać  $r2^m + 1$ , gdzie r jest liczbą naturalną, o czym pisałem w poprzedniej sekcji.

Jako A[i:j] będę oznaczał komórki tablicy ze współczynnikami wielomianu A o indeksach większych lub równych niż i oraz mniejszych lub równych j.

Drugim ulepszeniem jest użycie iteracyjnej szybkiej transformaty Fouriera [15]. Opiera się ona na obserwacji, że rekurencyjna wersja dyskretnej transformaty Fouriera polega, najpierw na podzieleniu współczynników wielomianu na coraz mniejsze grupy, aż do zawierających tylko pojedynczy współczynnik, a następnie, łaczeniu pojedynczych współczynników w pary zawierające informację o 2 współczynnikach, potem czwórki, ósemki itd aż do połączenia ich w jeden duży blok zawierający informacje o wszystkich współczynnikach, a rekurencyjne wywołania służa jedynie pogrupowaniu w jakiej kolejności będziemy wykonywać łączenia.

Możemy jednak to grupowanie wykonać bez kolejnych rekurencyjnych wywoływań transformaty po prostu ustawiając obok siebie współczynniki w takiej kolejności żeby współczynniki wielomianów stopnia  $2^l-1$ , które w wersji rekurencyjnej powstają na m-l poziomie rekursji były w spójnych segmentach  $A[0:2^l-1], A[2^l:2\cdot 2^l-1], A[2\cdot 2^l:3\cdot 2^l-1],..., A[(2^{m-l}-1)\cdot 2^l:2^m-1].$  Przy czym współczynniki wielomianu powstałego na l+1 poziomie rekursji, które w wielomianie powstałym na l-tym poziomie rekursji były przy potegach o wykładniku parzystym zostają umieszczone w "pierwszej połowie" segmentu długości  $2^l$ , w którym były umieszczone na poprzednim etapie, zaś te, które były przy potegach nieparzystych w drugim.

Zaważmy, że pierwsze "rozbicie" wektora współczynników w wersji rekurencyjnej sprowadza się do wybrania osobno współczynników parzystych i nieparzystych. Tak więc nasze grupowanie powinno w polach o indeksach  $(0,1,2,...,2^{m-1}-1)$  umieścić liczby znajdujące się, najpierw w polach o indeksach parzystych, czyli mające ostatni bit równy  $\emptyset$ , z kolei w polach o indeksach  $(2^{m-1}, 2^{m-1} + 1, ..., 2^m - 1)$ powinno umieścić liczby nieparzyste, czyli mające ostatni bit równy 1.

Pierwszy poziom rekursji rozbija wielomian  $A(x)=\sum_{i=0}^{2^m-1}a_ix^i$ , na  $A_0(x)=\sum_{i=0}^{2^{m-1}-1}a_{2i}x^i$  oraz  $A_1(x)=\sum_{i=0}^{2^{m-1}-1}a_{2i+1}x^i$ .

Gdy umieści<br/>my współczynniki  $A_0$  w  $A[0:2^{m-1}-1]$ , zaś  $A_1$  w  $A[2^{m-1}:2^m-1]$  należy umieścić współczynniki przy potęgach parzystych w wielomianie  $A_0$  w pierwszej połówce  $A[0:2^{m-1}-1]$ , nieparzyste zaś w drugiej. I analogicznie współczynniki przy potegach parzystych w wielomianie  $A_1$ 

w pierwszej połówce  $A[2^{m-1}:2^m-1]$ , nieparzyste zaś w drugiej. To który współczynnik jest przy potędze parzystej czy nie w wielomianach  $A_0$  i  $A_1$  decyduje to czy początkowo był przy potędze, której wykładnik miał drugi bit równy 0, czy 1. Dalsze kontynuowanie tego rozumowania prowadzi do wniosku, że jeżeli odwrócimy m-1 ostatnich bitów liczby i otrzymamy numer komórki, w której powinniśmy umieścić liczbę  $a_i$ . Istotnie załóżmy, że liczba powstała po odwróceniu m ostatnich bitów liczby i jest większa niż, że liczba powstała po odwróceniu m ostatnich bitów liczby j. Prosta indukcja pozwala stwierdzić, że współczynniki, których indeksy mają k wspólnych ostatnich bitów zostają na k-tym poziomie rekursji umieszczone w tym samym wielomianie. To czy zostaną umieszczone w pierwszej czy drugiej połowie segmentu, do którego były przypisane na k-tym poziomie rekursji zależy od tego czy ich k+1 bit jest równy 0 czy 1.

To, że liczba powstała po odwróceniu m ostatnich bitów liczby i jest większa niż liczba powstała po odwróceniu m ostatnich bitów liczby j oznacza, że pewna liczba k (być może równa 0) ostatnich bitów liczby i jest taka sama jak liczby j zaś k+1 ostatni bit liczby i jest równy 1, podczas gdy k+1 ostatni bit liczby j jest równy 0. Tak więc do k-tego poziomu rekursji  $a_i$  i  $a_j$  pozostają w tym samym wielomianie  $B(x) = \sum_{l=0}^{2^{m-k}-1} b_l x^l$ , czyli w wersji iteracyjnej są w tym samym segmencie długości  $2^{m-k}$  i na k+1 poziomie rekursji w wersji rekurencyjnej  $a_j$  jest umieszczane w wielomianie ze współczynnikami  $b_0, b_2, \ldots, b_{2^{m-k}-2},$  zaś  $a_i$  w wielomianie ze współczynnikami  $b_1, b_3, \ldots, b_{2^{m-k}-1},$  tak więc w wersji iteracyjnej  $a_j$  zostaje w umieszczone w pierwszej połowie segmentu, w którym są współczynniki  $b_0, b_1, \ldots, b_{2^{m-k}-1}$  zaś  $a_i$  w drugiej, tak więc  $a_i$  zostaje umieszczone w komórce o większym indeksie niż  $a_j$ . Ponieważ indeksy tablicy  $A[0:2^m-1]$  wyznaczają wszystkie możliwe binarne liczby m-bitowe to istotnie, jeżeli odwrócimy m-1 ostatnich bitów liczby i otrzymamy numer komórki, w której powinniśmy umieścić liczbę  $a_i$ .

Przejdźmy do dokładnego opisu naszej implementacji.

Najpierw definiuję funkcję enoughGoodRoot, która przyjmuje liczbę k typu \_\_int128 i zwraca element typu field, który jest pierwiastkiem z 1 stopnia  $2^k$ . Jest to po prostu podniesienie elementu field::almostPrimitiveRoot (będącego pierwiastkiem z 1 stopnia  $2^r$ , gdzie r to wartość zmiennej field::degreeOfDegree) field::almostPrimitiveRoot-k razy do kwadratu.

Kolejnym etapem jest odpowiednie ustawienie wartości w komórkach wektora ze współczynnikami wielomianu (nazwę go coefficients) tak by można było wykonać na nim iteracyjną wersję szybkiej transformaty Fouriera.

Funkcja reverseBits służy znalezienia indeksu komórki, w której powinna być umieszczona liczba znajdująca się początkowo w komórce o indeksie x, gdzie x jest pierwszym argumentem funkcji reverseBits typu long long, zaś drugim argumentem jest liczba k typu long long wyznaczająca ile ostatnich bitów x należy odwrócić.

Na początku zamieniamy miejscami bity o indeksach parzystych x z nieparzystymi. Robimy to, najpierw tworząc dwie kopie zmiennej x. W jednej z nich zerujemy (and-ując ją z odpowiednią maską) bity o indeksach parzystych, zaś w drugiej nieparzystych. Pierwszą kopię przesuwamy o 1 bit w prawo, tak, że bity o indeksach parzystych stały się bitami o indeksach nieparzystych, zaś drugą w lewo i wykonujemy na tak zmodyfikowanych kopiach operację or-a bitowego.

Analogiczną operację jak omówiona w poprzednim akapicie dla bloków składających się z 1-bitowych wykonujemy na blokach 2-bitowych, 4-bitowych, 8-bitowych, 16-bitowych, i 32-bitowych.

Tak zmodyfikowana zmienna x jest odwróconą bitowo początkową wartością zmiennej x. Ponieważ chcieliśmy odwrócić jedynie jej ostatnie k bitów przed zwróceniem x jako wyniku przesuwamy ją jeszcze o 64-k bitów w prawo bez znaku.

Gdy mamy już funkcję reverseBits możemy stworzyć funkcję setToDo transformującą wektor współczynników w wektor gotowy do wyliczenia jego szybkiej transformaty Fouriera. Jako argumenty dla tej funkcji otrzymujemy wektor elementów typu field o nazwie coefficients oraz zmienną long long o nazwie size oznaczającą żądaną długość wektora wynikowego (jest to odpowiednio duża potęga dwójki o wykładniku naturalnym). Na początku dopełniamy wektor coefficients elementami równymi field(0) do rozmiaru size. W zmiennej log zapisujemy wartość logarytmu o podstawie 2 na argumencie będącym długością wektora coefficients. Następnie w pętli z iteratorem i przechodzącym po wszystkich liczbach naturalnych od 0 do size-1 i jeżeli reverseBits(i,log) > i (warunek ten służy temu, by każdy element został zamieniony dokładnie raz. Zauważmy też, że reverseBits(reverseBits(i,log),log)=i) zamieniam w tabeli pole o indeksie i z polem o indeksie reverseBits(i,log) miejscami. Funkcja nic nie zwraca, a jedynie modyfikuje wektor podany jako argument.

Przejdźmy do funkcji DFT, która otrzymując wektor współczynników wielomianu coefficients, liczbę size nie mniejszą niż długość tego wektora i będący potęgą 2 o wykładniku naturalnym oraz obiekt omegaM typu field, który jest pierwiastkiem z 1 stopnia size zwraca wektor zawierający wartości tego wielomianu w punktach kolejno omegaM^0, omegaM^1,..., omegaM^size-1.

Poniżej umieściłem kod tej procedury.

```
void inline DFT(std::vector<field>&coefficients, long long size, field omegaM){
     setToDo(coefficients, size);
     std::stack<field> omegasM;
     while (omegaM != 1) {
          omegasM.push(omegaM);
          omegaM *= omegaM;
     \mathbf{long} \ \mathbf{long} \ \mathbf{m} = 1;
     while (!omegasM.empty()) {
          field currentOmegaM= omegasM.top();
          omegasM.pop();
          field\ omega = 1;
          m*=2;
          \label{eq:for} \mbox{for} (\mbox{long long } j = 0; \ j < m/2; j + = 1) \{
                \mathbf{for} (\mathbf{long} \ \mathbf{long} \ k = j; \ k \!\!<\! \! \mathtt{size}; \ k \!\!+\!\!\!=\!\! m) \{
                     field t = omega * coefficients[k+m/2];
                     field u = coefficients[k];
                     coefficients[k] = u+t;
                     coefficients[k+m/2] = u - t;
               omega *= currentOmegaM;
          }
     }
}
```

Na początku przygotowujemy wektor do wykonania dalszej części obliczeń wywołując zdefiniowaną wcześniej funkcję setToDo na wektorze coefficients i dla liczby size.

Tworzymy stos, na który kładziemy wyniki kolejnych złożeń podniesienia do kwadratu liczby omegaM aż do -1.

Póki stos nie będzie pusty, będę w każdej iteracji pętli while ściągał z niego kolejne wartości i przypisywał je do zmiennej current0megaM.

W dalszej części będę oznaczał jako  $\omega_i$  pierwiastek z 1 stopnia  $2^i$ , w  $\mathbb{Z}_p$ .

Przyjmijmy oznaczenie, że na początku i-tej iteracji wektor coefficients ma postać  $\frac{size}{2^{i-1}}$  bloków postaci  $(f_{i,k}(\omega_i^0), f_{i,k}(\omega_i^1), ..., f_{i,k}(\omega_i^{2^{i-1}-1}))$ , gdzie k to numer bloku. Chcemy następujące po sobie pary bloków połączyć w jeden blok postaci  $(f_{i+1,k}(\omega_{i+1}^0), f_{i+1,k}(\omega_{i+1}^1), ..., f_{i+1,k}(\omega_{i+1}^{2^i-1}))$ , przy czym  $f_{i+1,k}(\omega_{i+1}^j) = f_{i,2k}(\omega_i^{\frac{1}{2}}) + f_{i,2k+1}(\omega_i^{\frac{1}{2}})\omega_{i+1}^j.$ 

Kolejne iteracje pętli z iteratorem j odpowiadają kolejnym punktom, w których obliczamy wartości odpowiednich wielomianów, zaś pętli z iteratorem k numerom kolejnych rozpatrywanych wielomianów. Ponieważ  $\omega_{i+1}^{2^i}=-1$  wyliczenie  $f_{i+1,k}(\omega_{i+1}^j)$  i  $f_{i+1,k}(\omega_{i+1}^{j+2^i})$  wyliczam w jednej iteracji pętli. Przejdźmy do pełnej procedury mnożenia.

std::vector<field>multiplication(std::vector<field>A, std::vector<field>B){ long long size = 1;while(size < (long long)((A.size() + B.size()) +2 )){ size \*= 2;long long l = log(size);field omegaM = enoughGoodRoot(1); DFT(A, size, omegaM); DFT(B, size, omegaM);  $\label{eq:for} \mbox{for} \, (\, \mbox{long} \ \, \mbox{long} \ \, \mbox{i} = \! 0; \mbox{i} \! < \! \mbox{s} \, \mbox{i} \, \mbox{z} \, \mbox{e} \; ; \, \mbox{i} + \! + \! ) \{$ A[i] = B[i] \* A[i];omegaM = field(1)/omegaM;DFT(A, size, omegaM);  $\textbf{for}\,(\,\textbf{long long}\ i \!=\! 0; i \!<\! s\,i\,z\,e\;;\, i\,+\!+)\{$ A[i] /= field(size);return A;

Wektorów nie przekazuję przez referencje bo je modyfikuję.

Najpierw wliczamy wartość size będącą liczbą punktów, w których będziemy liczyć wartości wielomianu AB (jest to najmniejsza liczba będąca potęgą 2 o wykładniku naturalnym większa niż stopień AB). Kolejnym etapem jest znalezienie pierwiastka stopnia size z 1 w  $\mathbb{Z}_p$ . Następnie wyliczamy przez wywołania DFT na odpowiednich argumentach wektor  $(A(omegaM^0), A(omegaM^1), ..., A(omegaM^{s-1})),$ oraz  $(B(omegaM^0), B(omegaM^1), ..., B(omegaM^{s-1}))$ , gdzie s to wartość zmiennej size. Następnie w kopii wektora A zapisuje wartości AB w kolejnych punktach będące wartościami odpowiednich mnożeń.

Okazuje się, że aby zmienić, wektor  $(AB(omegaM^0), AB(omegaM^1), ..., AB(omegaM^{s-1}))$ , gdzie s jest wartością zmiennej size w wektor kolejnych współczynników AB wystarczy wywołać na nim DFT z drugim argumentem równym size i trzecim będącym równym odwrotności omegaM w  $\mathbb{Z}_p$ , a następnie, podzielić w  $\mathbb{Z}_p$  każdy jego element przez size.

#### Pochodna algebraiczna i jej własności

Klasyczna analityczna definicja pochodnej jest to przekształcenie funkcji f(x) w funkcję f'(x) taką, że  $f'(x) = \lim_{h \to 0} \frac{f(x+h) - f(x)}{h}$ . Definicja taka traci jednak cały sens jeżeli chcemy zmienić dziedzinę funkcji f i f' z liczb rzeczywistych na dziedzinę, gdzie nie możemy zmniejszać h w taki sposób, by było dowolnie małe lecz niezerowe. Przykładem takiej dziedziny jest ciało  $\mathbb{Z}_p$ .

Zauważmy, że jeżeli funkcja  $f \mathbb{R} \to \mathbb{R}$  jest gładka w okolicy 0, możemy ją utożsamić z jej szeregiem Taylora  $\sum_{i=0}^{\infty} f_i x^i$ .

Weźmy liczbę pierwszą p. W dalszej części sekcji będę zakładał, że współczynniki szeregu Taylora rozważanej funkcji są postaci  $\frac{a_i}{b_i}$ , gdzie  $a,b\in\mathbb{Z}$  i b jest niepodzielne przez p. Przy takim założeniu napis  $\sum_{i=0}^{\infty} \frac{a_i}{b_i} x^i$  zachowuje algebraiczny sens również w ciele reszt  $\mathbb{Z}_p$ , w którym liczbę całkowitą utożsamiamy z jej resztą z dzielenia przez p. W języku szeregów Taylora pochodną można zdefiniować jako przekształcenie funkcji  $f(x) = \sum_{i=0}^{\infty} f_i x^i$  w funkcję  $f'(x) = \sum_{i=0}^{\infty} (i+1) f_{i+1} x^i$ . Udowodnię teraz, że tak zdefiniowana pochodna, dla funkcji  $f(x) = \sum_{i=0}^{\infty} f_i x^i$  i  $g(x) = \sum_{i=0}^{\infty} g_i x^i$  zachowuje własności f' + g' = (f+g)', f' - g' = (f-g)', (fg)' = f'g + fg' oraz f(g)' = f'(g)g'.

```
Lemat: f' + g' = (f+g)' oraz f' - g' = (f-g)'

Dowód: f' + g' = \sum_{1}^{\infty} i f_i x^{i-1} + \sum_{1}^{\infty} i g_i x^{i-1} = \sum_{1}^{\infty} i (f_i + g_i) x^{i-1} = (f+g)' i analogicznie f' - g' = \sum_{1}^{\infty} i f_i x^{i-1} - \sum_{1}^{\infty} i g_i x^{i-1} = \sum_{1}^{\infty} (f_i - g_i) x^{i-1} = (f-g)'
```

```
Lemat: (fg)' = f'g + fg'.
Lemat: (fg)^i = f \ g + fg.

Dowód: (fg)' = ((\sum_{i=0}^{\infty} f_i x^i)(\sum_{i=0}^{\infty} g_i x^i))' = (\sum_{i=0}^{\infty} (\sum_{j=0}^{i} f_j g_{i-j}) x^i)' = \sum_{i=1}^{\infty} (\sum_{j=0}^{i} f_j g_{i-j}) i x^{i-1} = \sum_{i=0}^{\infty} (\sum_{j=0}^{i} f_j g_{i+1-j}) (i+1) x^i \text{ z kolei}

f'g + fg' = (\sum_{0}^{\infty} (i+1) f_{i+1} x^i)(\sum_{i=0}^{\infty} g_i x^i) + (\sum_{0}^{\infty} (i+1) g_{i+1} x^i)(\sum_{i=0}^{\infty} f_i x^i) = \sum_{i=0}^{\infty} (\sum_{j=0}^{i} f_{i+1-j} g_j (i+1-j)) x^i + \sum_{i=0}^{\infty} (\sum_{j=0}^{i} g_{i+1-j} f_j (i+1-j)) x^i = \sum_{i=0}^{\infty} (\sum_{j=0}^{i} g_{i+1-j} f_j (i+1-j)) x^
    (1-j+j)x^i = \sum_{i=0}^{\infty} (\sum_{j=0}^{i} g_{i+1-j}f_j)(i+1)x^i = (fg)'
```

Lemat: (f(g))' = f'(g)g'.

**Dowód:** Na początek przyjmijmy, że  $f(x) = x^k$ , gdzie k jest liczbą naturalną. Dla k = 0 i k=1 teza jest spełniona. Niech teza jest spełniona dla  $f(x)=x^l$  oraz dla każdego naturalnego kmniejszego niż l. Wtedy  $(g^k)' = ((g^{k-1})g)' = (g^{k-1})g' + g(g^{k-1})' = (g^{k-1})g' + g((k-1)g^{k-2}g') = (g^{k-1})g' + ((k-1)g^{k-1}g') = kg^{k-1}g'$ , tak więc na mocy zasady indukcji dla dowolnego k naturalnego jeżeli  $f(x) = x^k$  to (f(g))' = f'(g)g' dla dowolnego g postaci  $\sum_{i=0}^{\infty} g_i x^i$ . W takim razie dla dowolnego f postaci  $\sum_{i=0}^{\infty} f_i x^i$  zachodzi,  $(f(g))' = (\sum_{i=0}^{\infty} f_i g(x)^i)' = \sum_{i=0}^{\infty} f_i (g(x)^i)' = \sum_{i=0}^{\infty} f_i (g(x)^i$  $\sum_{i=0}^{\infty} f_i i g^{i-1}(x) g' = f'(g) g'.$ 

#### Implementacja algorytmu Jin i Wu

W tej części pracy dla funkcji F(x), której szereg Taylora ma postać  $\sum_{i=0}^{\infty} f_i x^i$  jako  $F_t$  będziemy oznaczać  $\sum_{i=0}^{t} f_i x^i$ .

Zasadnicza implementacja algorytmu Jin i Wu składa się z 4 funkcji.

Pierwszą z nich jaką omówię jest funkcja B, której zadaniem jest wyliczenie pierwszych t+1 współczynników szeregu Taylora  $B(x) = \ln(\prod_{i=1}^{n} (1 + x^{s_i})).$ 

Funkcja B wyznacza wektor t+1 pierwszych wyrazów szeregu Taylora w ciele  $\mathbb{Z}_p$  następującej funkcji:

$$B(x) = \ln \prod_{i=1}^{n} ((1+x^{s_i})) = \sum_{i=1}^{n} \ln(1+x^{s_i}) = \sum_{i=1}^{n} (\sum_{j=1}^{\infty} \frac{(-1)^{j-1}}{j} x^{s_i j})$$

Niech  $a_k$  będzie oznaczać liczbę elementów S równych k.

Przy tak przyjętych oznaczeniach

$$B_t(x) = \sum_{i=1}^n \left( \sum_{j=1}^{\lfloor \frac{t}{s_i} \rfloor} \frac{(-1)^{j-1}}{j} x^{s_i j} \right) = \sum_{k=1}^t \left( \sum_{j=1}^{\lfloor \frac{t}{k} \rfloor} \frac{a_k (-1)^{j-1}}{j} x^{jk} \right)$$

Spójrzmy na implementację funkcji B.

```
std::vector<field> B(std::vector<field> s, long long t){
     std::vector{<}field{}>~a(\,t{+}1,field\,(\,0\,)\,)\,;
     std::vector < field > ans(t+1, field(0));
     int K;
     for (int i = 0; i < s . size(); i++){
          if(s[i].getValue()<=t)a[s[i].getValue()] ++;
    for (long long k = 1; k <= t; k++){
for (long long j = 1; j <= t/k; j++){
field x = field(-1);
               ans [k*j] = ans [k*j] + a[k]*(x^(j-1))/field(j);
     return ans;
```

Na początku tworzę wektor a, którego k-ty element oznacza zdefiniowane wcześniej  $a_k$ . Reszta kodu jest prostym przetłumaczeniem matematycznej notacji sumy na składnię zawierającą pętle, przy czym pole ans[i] odpowiada współczynnikowi przy  $x^i$  w rozwinieciu w szereg Taylora funkcji B(x).

Kolejne dwie funkcje to compute i mainCompute.

Ich celem jest wyliczenie współczynników  $(\exp(B(x)))_t = (\sum_{i=0}^{\infty} \frac{B(x)^i}{i!})_t$ Algorytm ten bazuje na spostrzeżeniu, że żeby wyliczyć  $G_t(x)$ , gdzie  $G(x) = \exp(F(x))$  i  $F(x) = \sum_{i=0}^{\infty} \frac{B(x)^i}{i!}$ 

Algorytm ten bazuje na spostrzezeniu, ze zeby wynczyc  $G_t(x)$ , gdzie  $G(x) = \exp(F(x))$  i  $F(x) = \sum_{i=1}^{\infty} f_i x^i$ , jeżeli znamy G(0) wystarczy znaleźć wartości  $f_0, f_1, ..., f_t$ . Co więcej  $G_t(F(x)) = G_t(F_t(x))$  Niech rozwinięcie w szereg Taylora funkcji G ma postać  $\sum_{i=0}^{\infty} g_i x^i$  Zauważmy, że  $G'(x) = (\exp(F(x)))' = \exp(F(x))F'(x) = G(x)F'(x)$ , tak więc  $\sum_{i=0}^{\infty} (i+1)g_{i+1}x^i = (\sum_{i=0}^{\infty} g_i x^i)(\sum_{i=1}^{\infty} i f_i x^{i-1}) = \sum_{i=0}^{\infty} (\sum_{j=1}^{i+1} j f_j g_{i+1-j})x^i$  Tak więc  $(i+1)g_{i+1} = \sum_{j=1}^{i+1} j f_j g_{i+1-j}$ , czyli  $g_{i+1} = (i+1)^{-1}(\sum_{j=1}^{i+1} j f_j g_{i+1-j})$ . Zauważmy, że  $G(0) = g_0$ , tak więc mając wyliczone  $f_0, f_1, ..., f_t$  jesteśmy w stanie po kolei wyliczyć  $g_1, g_2, ..., g_t$ . Weźmy liczbę pierwszą p > t.

 $B(x) = \ln(\prod_{i=0}^{n} (1+x^{s_i})) = \sum_{i=1}^{n} (\sum_{k=1}^{\infty} \frac{(-1)^{k-1} x^{s_i k}}{k}) := \sum_{i=0}^{\infty} b_i x^i, \text{ więc każda z liczb } b_0, b_1, ..., b_t$  da się zapisać jako liczba wymierna postaci  $\frac{x}{y}$ , gdzie x, y to względnie pierwsze liczby naturalne i y nie jest podzielne przez p. Jeżeli x i y utożsamimy z resztą dzielenia ich przez p to wartość wyrażenia  $\frac{x}{x}$ da się wyliczyć w ciele  $\mathbb{Z}_p$ .

Niech  $A(x) = \exp(B(x)) = \prod_{i=0}^{n} (1+x^{s_i}) := \sum_{i=0}^{\infty} a_i x^i$ . Wiemy, że  $a_{i+1} = (i+1)^{-1} (\sum_{j=1}^{i+1} j b_j a_{i+1-j})$ , a także  $a_0 = \prod_{i=0}^{n} (1+0^{s_i}) = 1$ , więc każda z liczb  $a_i$ , gdzie  $i \in \{0,1,2,..,t\}$  da się przedstawić w postaci  $\frac{X_i}{Y_i}$ , gdzie  $X_i, Y_i$  to względnie pierwsze liczby naturalne i  $Y_i$  nie jest podzielne przez p. Jeżeli  $X_i$  i  $Y_i$  utożsamimy z resztą dzielenia ich przez p to wartość wyrażenia  $\frac{X_i}{Y_i}$  da się wyliczyć w ciele  $Z_p$  i wartość liczby  $a_i$  dla naturalnego i nie większego niż t jest równa 0 wtedy i tylko wtedy gdy dla jej postaci  $\frac{X_i}{Y_i}$  p dzieli  $X_i$ . Zauważmy, że A(x)

jest iloczynem wielomianów o całkowitych współczynnikach, więc też jest wielomianem o całkowitych współczynnikach, więc  $a_i$  jest wartością całkowitą, która w ciele  $Z_p$  jest utożsamiona z 0 wtedy i tylko wtedy, gdy jest podzielna przez p.

Na mocy powyższych rozważań, wykonuję dalsze obliczenia w ciele  $\mathbb{Z}_p$ , chyba, że explicite zaznaczę inaczej.

Procedura mainCompute jako argument przyjmuje wektor ft+1 pierwszych współczynników rozwinięcia w szereg Taylora funkcji B. Na początku inicjuje wynikowy t+1-elementowy wektor g ustawiając wszystkie jego komórki poza g[0] na 0, z kolei g[0] ustawiamy na 1. Następnie uruchamiamy funkcję compute na argumentach 0, t, g i f.

Funkcja compute zapisuje do wektora podanego jako trzeci argument (oczywiście przez referencję, żeby można było go modyfikować) wartości kolejnych współczynników szeregu Taylora funkcji  $g(x) = \exp(\sum_{i=0}^t f_i x^i)$ , gdzie t+1 to długość wektora podanego jako czwarty argument, zaś  $f_i$  to wartość i-tej komórki wektora podanego jako czwarty argument. W dalszej części jako  $f_i$  będę oznaczał wartość i-tej komórki wektora podanego jako czwarty argument, zaś jako  $g_i$  będę oznaczał wartość i-tej komórki wektora podanego jako trzeci argument. Nie będę traktować  $g_i$  jak "zwykłą" liczbę, ale wartość zmieniającą się w czasie wykonywania programu, gdy zmienia się wartość odpowiadającej jej komórki wektora. Jako t będę oznaczał f.size()-1

Idea funkcji compute bazuje na tym, że aby wyliczyć  $g_i = (i+1)^{-1} (\sum_{j=1}^{i+1} j f_j g_{i+1-j})$  dla wszystkich  $i \in \{1, 2, ..., t\}$  należy wykonać  $O(n^2)$  dodawań składników postaci  $(i+1)^{-1} j f_j g_{i+1-j}$  do odpowiednich komórek. Nie każde dodawanie można wykonać w dowolnym momencie, ponieważ wartości komórek wektora g ulegają zmianie. Dodawanie uznamy za dozwolone, jeżeli  $g_{i+1-j}$  obecne w dodawanym składniku  $(i+1)^{-1} f_j g_{i+1-j}$  nie ulega zmianie.

Zapisana w pseudokodzie funkcja compute ma postać:

#### **Function** compute(1, r,g,f):

Po wykonaniu compute(1,r,f,g) chcemy, żeby wartości  $g_l, g_{l+1}, ..., g_r$  były już ustawione na wartości docelowe, zaś przed wykonaniem compute(1,r,f,g) chcemy, żeby wszystkie składniki postaci  $(i+1)^{-1}f_jg_{i+1-j}$ , gdzie i+1-j < l zostały już dodane do odpowiednich komórek g o indeksach należących do  $\{0,1,...,r\}$ . Chcemy też, żeby każda operacja dodawania była dozwolona.

Jeżeli długość g jest równa 0 to żądania napisane w poprzednim akapicie są spełnione. Załóżmy indukcyjnie, że są spełnione dla g długości 0, 1, 2, ..., t-1. Niech długość g jest równa t.

Wywołanie compute(0,t,f,g) sprowadza się najpierw do wywołania rekurencyjnego compute(0,m,f,g), gdzie m to wynik wykonanej w liczbach całkowitych działania  $\lfloor \frac{t}{2} \rfloor$ . Po jej wykonaniu z tezy indukcyjnej  $g_0,g_2,...,g_m$  mają docelowe wartości. Następnie przechodzimy do wykonania pętli

```
\begin{array}{l} \text{for } i \leftarrow \texttt{m+1,m+2,\dots,r} \ do \\ \mid \text{ for } j \leftarrow \texttt{1,l+1,\dots,m} \ do \\ \mid \text{ } g[\texttt{i}] \leftarrow \text{g[i]+(i-j)f[i-j]g[j]/i} \\ \mid \text{ end} \\ \end{array}
```

Ponieważ indeks j jest nie większy niż m, wszystkie dodawania są dozwolone. Po wykonaniu tej pętli zostają już wykonane wszystkie potrzebne dodania wyrazów postaci g[i]+(i-j)f[i-j]g[j]/i, gdzie j jest nie większe niż m. Następnie wykonujemy compute(m+1,r,g,f), co przypomina wywołanie compute(0,r-m-1,f,g) z tą modyfikacją, że w momencie gdy wykonalibyśmy linię g[i] <-g[i]+(i-j)f[i-j]g[j]/i każde wystąpienie zmiennych i i j zastępujemy odpowiednio zmiennymi i+m+1 i j+m+1. Ponieważ zgodnie z tezą indukcyjną po wykonaniu compute(0,r-m-1,f,g),  $g_i$  zostaje zwiększone o  $(i+1)^{-1}(\sum_{j=1}^{i+1} jf_jg_{i+1-j})$ , dla  $i \in \{1,2,...,r-m-1\}$  to po wykonaniu compute(m+1,r,f,g),

 $g_{i+m+1}$  zostaje zwiększone o  $(m+1+i+1)^{-1}(\sum_{j=1}^{i+1}jf_{m+1+j}g_{m+1+i+1-j})$ , dla  $i\in\{1,2,...,r-m-1\}$ , więc po wykonaniu compute(m+1,r,g,f)  $g_i=(i+1)^{-1}(\sum_{j=1}^{i+1}jf_jg_{i+1-j})$  dla każdego  $i\in\{0,1,2,3,...,t\}$ .

Nasza implementacja jednak korzysta z jednego usprawnienia. Zauważmy, że iloczyn wielomianów  $F(x) = \sum_{k=0}^{r-l} k f_k x^k$  i  $G(x) = \sum_{j=0}^{m-l} g_{j+l} x^j$ , ma postać  $\sum_{i=0}^{r+m-2l} (\sum_{k=0}^{r-l} k f_k g_{i-k+l}) x^i$ , tak więc w tym iloczynie współczynnik przy potędze  $x^{i-l}$  podzielony przez i jest równy liczbie, o którą zostaje zwiększone  $g_i$  po wykonaniu pętli

```
\begin{array}{ll} \text{for } i \leftarrow \texttt{m+1,m+2,\dots,r} \text{ do} \\ & \mid \text{ for } j \leftarrow \texttt{1,l+1,\dots,m} \text{ do} \\ & \mid \text{ g[i]} \leftarrow \text{g[i]+(i-j)f[i-j]g[j]/i} \\ & \mid \text{ end} \end{array}
```

Wykonanie pętli naiwnie zajmuje czas  $O(t^2)$ , zaś wykorzystanie szybkiej teorioliczbowej transformaty Fouriera do mnożenia wielomianów, w mojej implementacji przyspieszyć wykonanie tej pętli do  $O(t \ln(t))$ . Niech T(t) oznacza czas wykonania compute, gdzie różnica między drugim i pierwszym argumentem wynosi t+1. Ponieważ  $T(t)=2T(\frac{t}{2})+O(t \ln(t))$ , to  $T(t)=O(t \ln^2(t))$ .

Kolejną ostatnią już implementowaną przeze mnie funkcją jest JinWu. Przyjmuje ona wektor s elementów zbioru S, oraz liczbe t. Na jpierw losuje ona liczbe pierwsza p, która jest wynikiem wykonania funkcji find\_prime(s.size(),t). Następnie wywołując field::setP(p) ustawiam zmienne statyczne klasy field tak, żeby obliczenia w niej wykonywane odpowiadały wykonaniu ich w klasie  $\mathbb{Z}_p$ . Potem do wektora  $\mathsf{Bans}$  przy pomocy wykonania funkcji  $\mathsf{B}(\mathsf{s},\mathsf{t})$  zapisuję t+1 pierwszych współczynników (w  $\mathbb{Z}_p$ ) szeregu Taylora funkcji  $B(x) = \ln(\prod_{i=0}^{n-1}(1+x^{s_i}))$ , gdzie jako n oznaczam długość wektora s, zaś jako  $s_i$  oznaczam jego i-tą komórkę w  $\mathbb{Z}_p$  (będę to oznaczenie stosował również w dalszej części pracy). Następnie do wektora compute Ans zapisuję t+1 pierwszych współczynników (w  $\mathbb{Z}_p$ ) szeregu Taylora funkcji  $A(x) = \prod_{i=0}^{n-1} (1+x^{s_i})$  jako wynik procedury mainCompute(t,Bans). Zauważmy, że ponieważ A(x) jest wielomianem współczynnik przy potędze  $x^i$  w jego rozwinięciu w szereg Taylora jest po prostu współczynnikiem przy potędze  $x^i$  w wielomianie A(x), zaś współczynnik przy potędze  $x^i$  w A(x) oznacza ilość sposobów wybrania ciągu indeksów naturalnych  $-1 < i_1 < i_2 < \ldots < i_m <$ n, takich, że  $x^{s_{i_1}+s_{i_2}+...+s_{i_m}}=x^i$ , czyli liczba podzbiorów S dających sumę i. Ponieważ liczby te zapisujemy jako elementy  $\mathbb{Z}_p$  możliwe, compute<br/>Ans[t] jest równe 0 mimo, że istnieją podzbiory So sumie t jednak ich liczba jest podzielna przez p. Jednak liczba tych podzbiorów na pewno jest nie wieksza niż  $2^n$ , wiec ma co najwyżej n różnych czynników pierwszych. Eksperymenty w sekcji poświęconej losowaniu liczby pierwszej pozwalają założyć, że liczba możliwych do wylosowania wartości p jest  $O(\frac{(n+t)^3}{\log(n+t)}) = O((n+t)^2)$ , więc prawdopodobieństwo, że p dzieli niezerową liczbę podzbiorów So sumie t jest  $O(\frac{n}{(n+t)^2}) = O(\frac{1}{n+t})$ .

## 9 Wyniki

Poniżej prezentuję wyniki działania mojego algorytmu w porównaniu z algorytmem klasycznym omówionym w sekcji drugiej używającym bitset-u o 1000001 elementów. Testy zostały wykonane na komputerze z procesorem Intel i5-7300HQ (4) @ 3.500GHz i odnoszą się do drugiej wersji Problemu Sumy Podzbiorów.

n	t	Czas Jin Wu	Czas alg. dyn.	poprawne
100000	1000000	315362 ms	4267.49 ms	1000001/1000001
100000	100000	$25851 \mathrm{ms}$	5179.56 ms	100001/100001
100000	10000	$560.921 \mathrm{ms}$	4784.02 ms	10001/10001
100000	1000	$47.9454 \mathrm{ms}$	4019.89 ms	1001/1001
100000	100	$21.6081 \mathrm{ms}$	3947.29 ms	101/101
10	1000000	172077 ms	3.82472 ms	1000001/1000001
100	1000000	221943 ms	6.63483 ms	1000001/1000001
1000	1000000	235951 ms	45.9866 ms	1000001/1000001
10000	1000000	290675 ms	472.921 ms	1000001/1000001
100000	1000000	299593 ms	$4660.25 \mathrm{ms}$	1000001/1000001

#### Literatura

- [1] Ashish Agarwal. Encrypting messages using the merkle-hellman knapsack cryptosystem. *IJCSNS*, 11(5):12, 2011.
- [2] Eric Bach. Comments on search procedures for primitive roots. *Mathematics of computation*, 66(220):1719–1727, 1997.
- [3] Anja Becker, Jean-Sébastien Coron, and Antoine Joux. Improved generic algorithms for hard knapsacks. In Advances in Cryptology-EUROCRYPT 2011: 30th Annual International Conference on the Theory and Applications of Cryptographic Techniques, Tallinn, Estonia, May 15-19, 2011. Proceedings 30, pages 364–385. Springer, 2011.
- [4] David Biesner, Rafet Sifa, and Christian Bauckhage. Solving subset sum problems using binary optimization with applications in auditing and financial data analysis. 2022.
- [5] Konrad Durnoga and Jacek Pomykała. Large sieve, miller-rabin compositeness witnesses and integer factoring problem. Fundamenta Informaticae, 156(2):179–185, 2017.
- [6] Hari Krishna Garg. Digital signal processing algorithms: number theory, convolution, fast Fourier transforms, and applications. Routledge, 2017.
- [7] Dorian Goldfeld. The elementary proof of the prime number theorem: An historical perspective. In *Number Theory: New York Seminar 2003*, pages 179–192. Springer, 2004.
- [8] Ellis Horowitz and Sartaj Sahni. Computing partitions with applications to the knapsack problem. Journal of the ACM (JACM), 21(2):277–292, 1974.
- [9] Nick Howgrave-Graham and Antoine Joux. New generic algorithms for hard knapsacks. In Advances in Cryptology-EUROCRYPT 2010: 29th Annual International Conference on the Theory and Applications of Cryptographic Techniques, French Riviera, May 30-June 3, 2010. Proceedings 29, pages 235-256. Springer, 2010.
- [10] Ce Jin and Hongxun Wu. A simple near-linear pseudopolynomial time randomized algorithm for subset sum. arXiv preprint arXiv:1807.11597, 2018.
- [11] Silvano Martello and Paolo Toth. A mixture of dynamic programming and branch-and-bound for the subset-sum problem. *Management Science*, 30(6):765–771, 1984.
- [12] Tomohiro Sasamoto, Taro Toyoizumi, and Hidetoshi Nishimori. Statistical mechanics of an np-complete problem: subset sum. *Journal of Physics A: Mathematical and General*, 34(44):9555, 2001.
- [13] Richard Schroeppel and Adi Shamir. A  $t=o(2^n/2)$ ,  $s=o(2^n/4)$  algorithm for certain np-complete problems. SIAM journal on Computing, 10(3):456–464, 1981.
- [14] Zhongde Wang. Fast algorithms for the discrete w transform and for the discrete fourier transform. *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 32(4):803–816, 1984.
- [15] Frank Wyrowski and Olof Bryngdahl. Iterative fourier-transform algorithm applied to computer holography. *JOSA A*, 5(7):1058–1065, 1988.